

电信用户深度挖掘与多类型预测模型构建： 从总收入回归到行为分类

数据挖掘原理与技术第3次个人作业



汇报人：钟忠权

时间：2025.11.17



目 录

CONTENTS

01

项目背景与数据介绍

02

探索性数据分析与特征工程

03

任务1

04

任务2-5

05

模型整体对比与总结



01

项目背景与数据介绍



数据基本情况

记录数：8999，字段数：23

缺失值概览

缺失数量 缺失比例(%)

最近使用操作系统偏好 1010 11.22

终端品牌 465 5.17

年龄 219 2.43

终端类型 4 0.04

换机频率 1 0.01

入网渠道类型 1 0.01

渠道类型描述 1 0.01

上网流量使用 1 0.01

漫游流量使用 1 0.01

总收入 1 0.01

增值收入 1 0.01

流量收入 1 0.01

短信收入 1 0.01

彩信收入 1 0.01

语音收入 1 0.01

是否欠费 1 0.01

产品大类 1 0.01

产品分类 1 0.01

A	B	C	D	E	F	G	H	I	J
用户ID	性别	年	归属	客户类型	在网时	换机频率	终端品牌	终端类	最近使用操作系统偏好
00891A97F	女	20	石家庄	公众客户	15	频繁换机型	LG	4G	ANDROID 5.1.0
00F84124C	女	63	北京	公众客户	70	频繁换机型	苹果	3G	IOS 6.0
0129B973E	男	21	北京	公众客户	33	频繁换机型	三星	4G	ANDROID 5.1.1
015B82EFB	无法区分		北京	集团-中小企	1	频繁换机型	华为	4G	ANDROID 5.0.2
01EA77A21	男	32	北京	公众客户	58	频繁换机型	黑莓	3G	BLACKBERRY
01EBB91E4	男	20	天津	公众客户	45	频繁换机型	苹果	4G	IOS 9.0
02771333B	男	23	北京	公众客户	45	频繁换机型	摩托罗拉	4G	ANDROID 5.0.1
02D556F64	男	47	天津	公众客户	47	频繁换机型	华为	4G	ANDROID 5.1.1
02E00D5F4	男	34	北京	公众客户	24	频繁换机型	苹果	4G	IOS 8.0
03C44E8Df	女	18	北京	公众客户	1	频繁换机型	魅族	4G	
03FB7FC1E	男	26	邯郸	公众客户	2	频繁换机型		0	
041A728C4	女	45	承德	公众客户	65	频繁换机型	小米	4G	ANDROID 4.4.2
042D41E3E	男	19	天津	公众客户	1	频繁换机型	三星	4G	ANDROID 4.3
0486E0CC7	男	28	北京	公众客户	33	频繁换机型	苹果	4G	IOS 9.0
055E74FA1	男	38	邯郸	公众客户	1	频繁换机型		0	
056BC202E	女	19	北京	公众客户	36	频繁换机型	苹果	3G	IOS 6.0
06BA8104F	男	25	天津	公众客户	32	频繁换机型	苹果	4G	IOS 8.0
07BF8F288	男	21	承德	公众客户	7	频繁换机型	三星	4G	ANDROID 4.0.4

公众客户样本数：8846 (占全部用户 98.30%)。

(后续任务统一使用这个子集)

目标：多任务建模（1 回归 + 4 分类），尽量提高预测的准确度。



数据基本情况

连续变量（10个）

变量名	说明
年龄	用户年龄
在网时长	用户入网时长，对收入与欠费均有影响
上网流量使用	明显右偏，存在极端值
漫游流量使用	右偏，大部分为0
总收入	每月总收入（任务1回归目标）
增值收入	子项
流量收入	子项
短信收入	子项
彩信收入	子项
语音收入	子项

将明显的数值列转为 numeric（错误转为 NaN）

分类变量（13个）

变量名	说明
用户 ID	用户唯一标识（不参与建模）
性别	男 / 女 / 无法区分
归属地	用户所属地区
客户类型	客户类型（公众客户为主要分析对象）
换机频率	频繁换机/偶尔换机/从不换机
终端品牌	手机品牌（高基数类别）
终端类型	2G / 3G / 4G（任务3预测目标）
最近使用操作系统偏好	ANDROID / IOS（任务5目标）
入网渠道类型	用户入网方式：1/2/99
渠道类型描述	社会渠道 / 自有渠道（任务4目标）
是否欠费	是 / 否（二分类，严重不平衡，任务2目标）
产品大类	电信产品的大类
产品分类	产品细分类型（高基数类别）



02

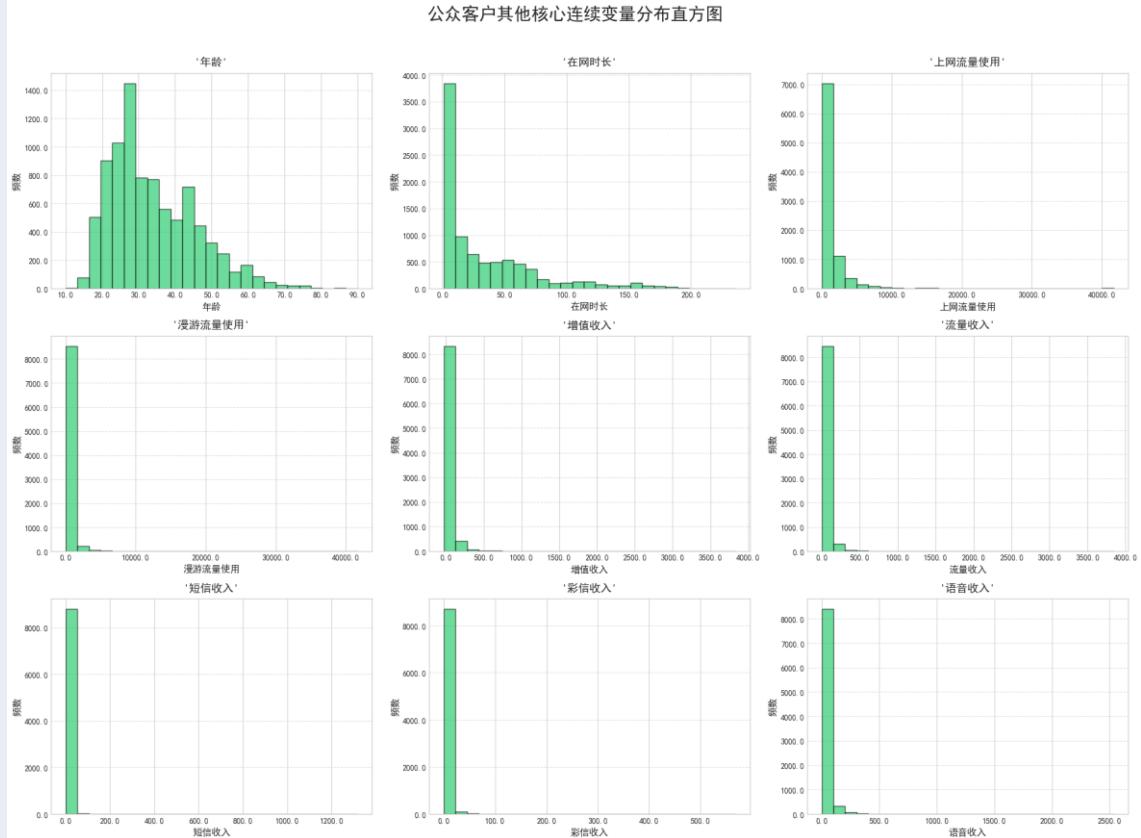
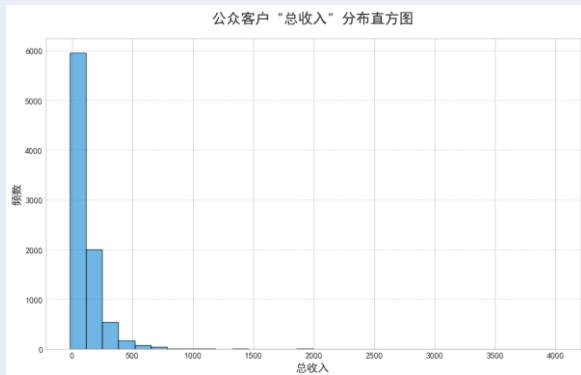
探索性数据分析
与特征工程

基于公众客户样本



连续变量

公众客户样本数：8846 (占全部用户 98.30%)



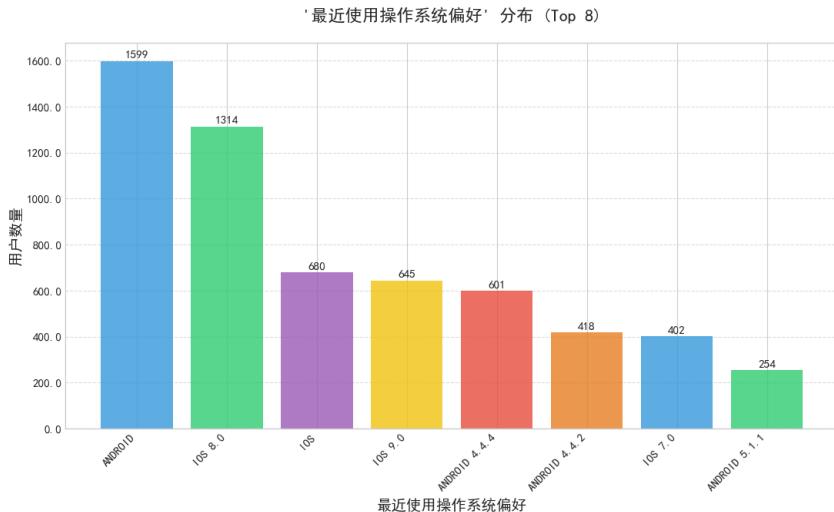
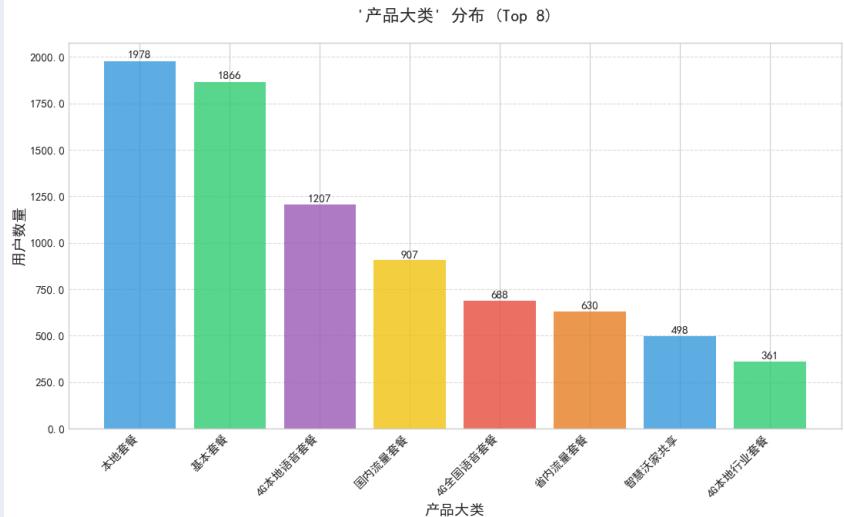
除年龄外，基本严重右偏



分类变量情况

公众客户样本数：8846 (占全部用户 98.30%)

公众客户分类变量分布（条形图）



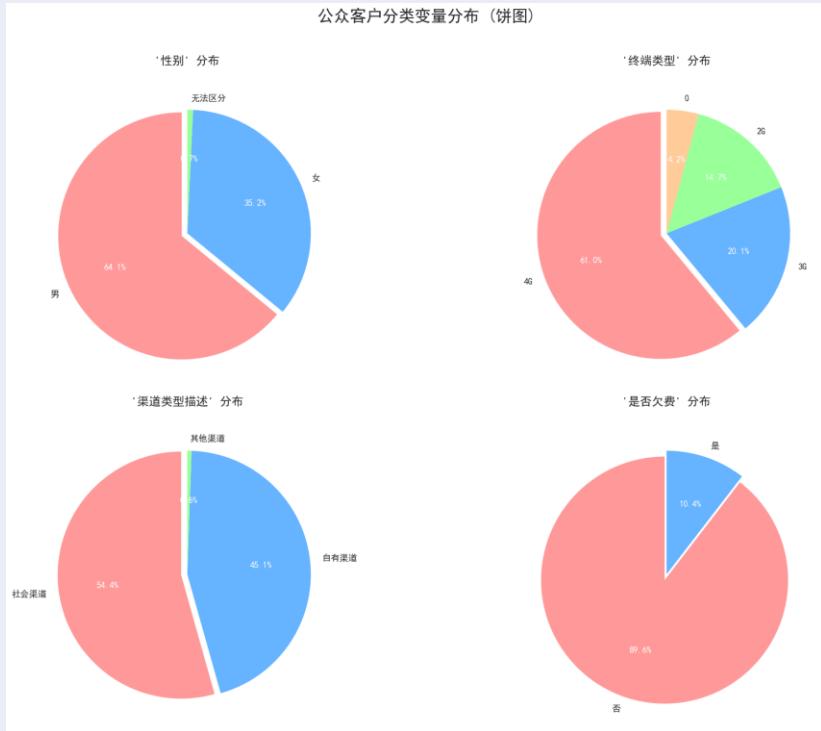
“产品大类”中，本地套餐最多；

“最近使用操作系统偏好”中有许多相同系统的具体版本数据，后续需要合并。



分类变量情况

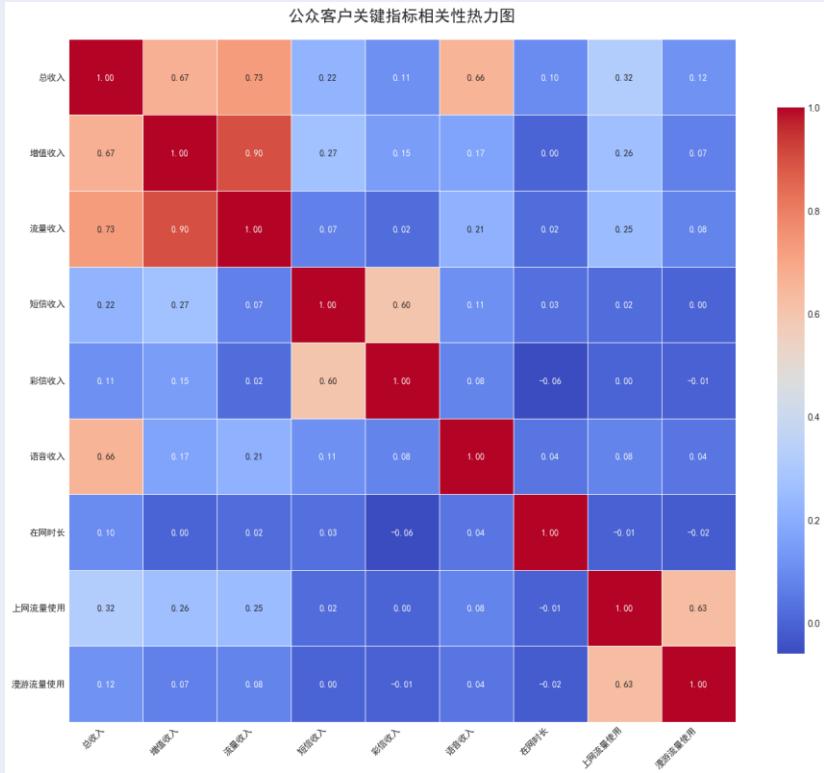
公众客户样本数：8846 (占全部用户 98.30%)



“是否欠费”类别严重不平衡



连续变量相关性分析



收入数据之间、上网流量使用和漫游流量使用之间相关性强，符合直观

- 强正相关：

增值收入与流量收入 (0.90)：用户流量使用越多，增值服务消费也越高

总收入与流量收入 (0.73)：流量收入是总收入的重要组成部分

短信收入与彩信收入 (0.66)：使用短信的用户更可能同时使用彩信服务

- 弱相关 / 无显著关联：

在网时长与多数收入指标相关性微弱，说明用户忠诚度对收入影响不明显

漫游流量使用与其他指标关联度低，表明漫游业务目前贡献有限

- 唯一弱负相关：

在网时长与彩信收入 (-0.06)、漫游流量 (-0.02)，相关性几乎可忽略



特征工程

统一特征工程：

- 删除指定列
- 划分 X, y
- 数值缺失：中位数填补
- 类别缺失：填 'Unknown'
- 类别：One-hot 编码

```
# 1. 划分 X, y
if target_col:
    y = df[target_col]
    X = df.drop(columns=[target_col] + drop_cols)
else:
    y = None
    X = df.drop(columns=drop_cols)

# 2. 缺失值处理
num_cols = X.select_dtypes(include=[np.number]).columns
cat_cols = X.select_dtypes(include=["object"]).columns

# 数值：中位数填补
X[num_cols] = X[num_cols].fillna(X[num_cols].median())

# 类别：填 "Unknown"
X[cat_cols] = X[cat_cols].fillna("Unknown")

# 3. One-hot 编码
X = pd.get_dummies(X, drop_first=True)
ohe_cols = X.columns.tolist()
```



03

任务1

使用线性回归模型和随机森林预测

总收入，并汇报RMSE和MAE

下列变量除外：[增值收入],[流量收入],[短信收入],[彩信收入],[语音收入]



线性回归模型

目标变量“总收入”存在1个缺失值，已用中位数（74.20）填充

数值变量多重共线性（VIF）检测：

变量 VIF

0 年龄	1.985794
1 在网时长	1.854073
2 上网流量使用	1.904400
3 漫游流量使用	1.701312

均小于10

模型：

总收入 ~ 年龄 + 在网时长 + 上网流量使用 + 漫游流量使用 + 性别_女 + 性别_男.....

训练集 RMSE: 138.63, MAE: 61.50

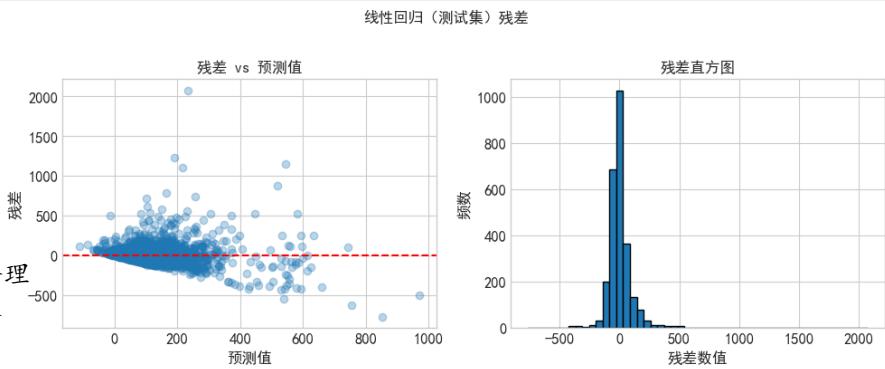
测试集 RMSE: 117.40, MAE: 64.85

模型基本假设满足：残差无明显趋势，说明线性模型对数据的整体拟合形式合理
预测精度特征：对中低收入样本预测较稳定，对高收入样本预测误差波动更大

```
rf_exclude_cols = ["用户ID", "客户类型", "增值收入", "流量收入", "短信收入", "彩信收入", "语音收入"]  
  
y_rf = df["总收入"]  
X_rf = df.drop(columns=["总收入"] + rf_exclude_cols)
```

OLS Regression Results
=====

Dep. Variable:	总收入	R-squared:	0.373
Model:	OLS	Adj. R-squared:	0.338
Method:	Least Squares	F-statistic:	10.79
Date:	Sat, 15 Nov 2025	Prob (F-statistic):	0.00
Time:	18:06:37	Log-Likelihood:	-39324.
No. Observations:	6192	AIC:	7.930e+04
Df Residuals:	5868	BIC:	8.148e+04
Df Model:	323		
Covariance Type:	nonrobust		





随机森林

```
rf_exclude_cols = ["用户ID", "客户类型", "增值收入", "流量收入", "短信收入", "彩信收入", "语音收入"]  
  
y_rf = df["总收入"]  
X_rf = df.drop(columns=["总收入"] + rf_exclude_cols)
```

GridSearchCV调参

最佳参数: {'max_depth': 12, 'max_features': 0.5, 'min_samples_leaf': 1, 'min_samples_split': 5, 'n_estimators': 300}

训练 RMSE: 81.70, MAE: 39.75

测试 RMSE: 104.89, MAE: 52.58

随机森林特征重要性 TOP5:

	特征	重要性
3	上网流量使用	0.283217
4	漫游流量使用	0.132042
357	产品分类_596元基本套餐（含国内语音3000分钟，国内流量11GB）	0.097006
1	在网时长	0.068570
0	年龄	0.065395

最终结论: 随机森林在训练集(拟合能力)和测试集(预测能力)均表现更好



04

任务2-5

任选3个模型进行分类



模型选择思路

- 鉴于本项目数据集特征包含大量类别型变量（如终端品牌、套餐类型）及右偏的连续变量（如流量使用、收入等），随机森林、XGBoost、逻辑回归普遍表现优于SVM、神经网络、朴素贝叶斯、k近邻算法。
- 数据特点：高维 one-hot 特征与强特征相关性。**
- 朴素贝叶斯：基于特征条件独立假设
- SVM：更适合特征维度低、样本量小、数据分布相对均匀
- 神经网络：需要大规模数据、强非线性关系建模，且特征需经过精细预处理
- k近邻：适合样本量小、特征维度低、局部模式明显的场景
- 因此，本项目重点考虑逻辑回归、随机森林、XGBoost，进行深入比较和调参。

分别汇报：**a)混淆矩阵， b)预测准确度/精度，
c)Precision（查准率），d)Recall（查全率）。**
对3个模型中的至少一个模型，汇报：ROC 曲线。

统一建模流程：





任务2：是否欠费

有效样本数量： 8845

---- LogisticRegression ----

混淆矩阵：

```
[[1060 524]
 [ 70 115]]
```

---- RandomForest ----

混淆矩阵：

```
[[1472 112]
 [122 63]]
```

		PREDICTED CLASS	
		Class=Yes	Class>No
ACTUAL CLASS	Class=Yes	a (TP)	b (FN)
	Class>No	c (FP)	d (TN)

---- XGBoost ----

混淆矩阵：

```
[[1382 202]
 [102 83]]
```

===== 三模型对比（任务2）=====

	Accuracy	Precision	Recall	F1	ROC-AUC
--	----------	-----------	--------	----	---------

XGBoost	0.828151	0.291228	0.448649	0.353191	0.754784
---------	----------	----------	----------	----------	----------

RandomForest	0.867722	0.360000	0.340541	0.350000	0.747048
--------------	----------	----------	----------	----------	----------

LogisticRegression	0.664217	0.179969	0.621622	0.279126	0.689882
--------------------	----------	----------	----------	----------	----------

最佳模型：XGBoost

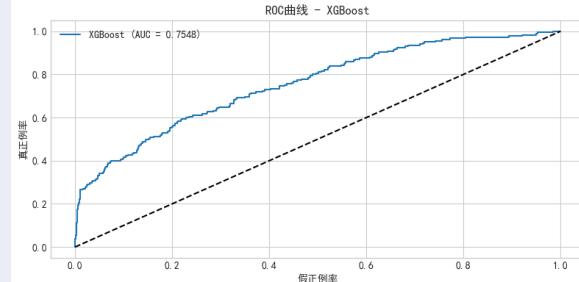
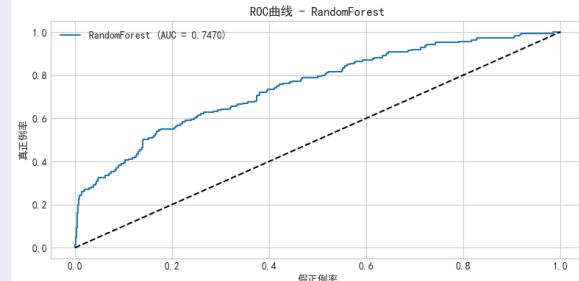
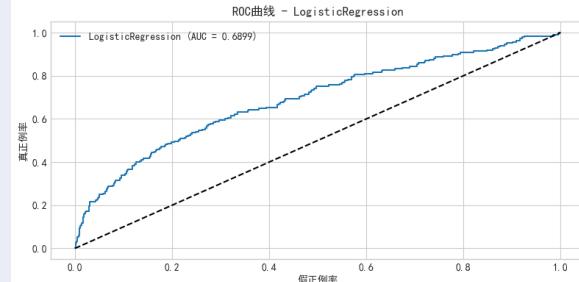
核心原因：

任务2是严重不平衡的二分类问题（欠费样本占比低），此时ROC-AUC（反映整体分类能力）和F1分数（平衡精确率和召回率）是更重要的指标。

XGBoost的ROC-AUC（0.7548）和F1分数（0.3532）均优于其他模型，尤其在召回率（0.4486）上明显高于随机森林（0.3405），说明其能更好地识别出“欠费”这一少数类（对不平衡数据更敏感）。

随机森林虽然准确率更高（0.8677），但主要是通过“偏向多数类（不欠费）”实现的，对少数类的识别能力较弱，不适合不平衡场景。

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$





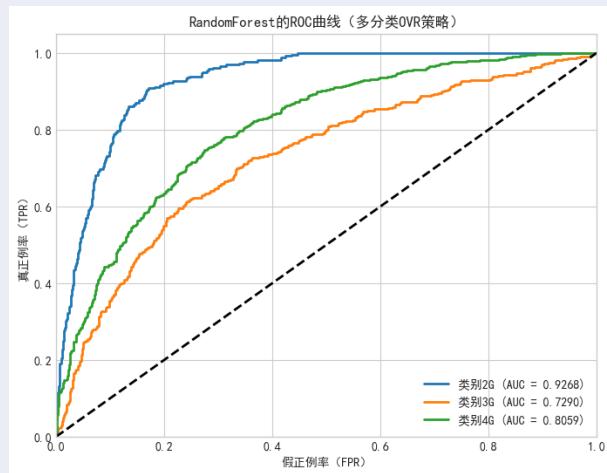
任务3：终端类型=2G、3G、4G

有效样本数： 8472

任务3：模型对比

	Accuracy	Macro-F1
RandomForest	0.694985	0.631291
XGBoost	0.722124	0.593926
MultinomialLogit	0.686726	0.446029

模型	混淆矩阵（实际-预测）	准确度	查准率（类别 0/1/2）	查全率（类别 0/1/2）
MultinomialLogit	[[122,0,139],[42,0,313],[37,0,1042]]	0.6867	0.61/0.00/0.70	0.47/0.00/0.97
RandomForest	[[218,7,36],[72,150,133],[110,159,810]]	0.6950	0.55/0.47/0.83	0.84/0.42/0.75
XGBoost	[[171,10,80],[39,74,242],[50,50,979]]	0.7221	0.66/0.55/0.75	0.66/0.21/0.91



•最佳模型：随机森林

•核心原因：

•多分类任务中，宏 F1（Macro-F1）是关键指标（反映模型对所有类别的平均表现，不受样本不平衡影响）。

•随机森林的宏 F1 (0.6313) 显著高于 XGBoost (0.5939) 和逻辑回归 (0.4460)，尤其在“3G”这一中间类别上表现更均衡（召回率 0.42, F1=0.45），而 XGBoost 对“3G”的识别能力极差（召回率仅 0.21）。

•随机森林的集成特性使其在处理多类别、复杂特征交互时更稳健，不易受某一占比高的类别（如 4G，样本量最大）主导。



任务4和5中的数据泄露问题

```
# 操作系统类型清洗
def simplify_os(x):
    if isinstance(x, str):
        xu = x.upper()
        if "ANDROID" in xu:
            return "ANDROID"
        if "IOS" in xu:
            return "IOS"
    return None

df5 = df_public.copy()
df5["最近使用操作系统偏好"] = df5["最近使用操作系统偏好"].apply(simplify_os)
df5 = df5[df5["最近使用操作系统偏好"].isin(["ANDROID", "IOS"])].copy()

# 1. 统计终端品牌和最近使用操作系统偏好的组合数据
brand_os_counts = df5.groupby(['终端品牌', '最近使用操作系统偏好']).size().sort_values(ascending=False)

# 2. 统计入网渠道类型和渠道类型描述的组合数据
channel_desc_counts = df5.groupby(['入网渠道类型', '渠道类型描述']).size().sort_values(ascending=False)
```



终端品牌和最近使用操作系统偏好组合统计:

终端品牌 最近使用操作系统偏好

苹果	IOS	3289
小米	ANDROID	866
三星	ANDROID	851
华为	ANDROID	803
维沃	ANDROID	431

...

锤子（作废）	ANDROID	1
飞利浦	ANDROID	1
骋娱传媒	ANDROID	1
鸿锦	ANDROID	1
黑莓	ANDROID	1

Length: 135, dtype: int64

入网渠道类型和渠道类型描述组合统计:

入网渠道类型 渠道类型描述

2.0	社会渠道	4210
1.0	自有渠道	3580
99.0	其他渠道	45

dtype: int64

“终端品牌”和“最近使用操作系统偏好”实际的信息是相同的。
“入网渠道类型”和“渠道类型描述”实际的信息是相同的。
两者不能同时出现。



任务4：渠道类型描述=社会渠道和自有渠道

有效样本数： 8796

```
drop_cols = ["用户ID", "客户类型", "入网渠道类型"]
X, y, _ = preprocess_features(df4, target_col="渠道类型描述", drop_cols=drop_cols)
```

删除“入网渠道类型”字段以解决数据泄露

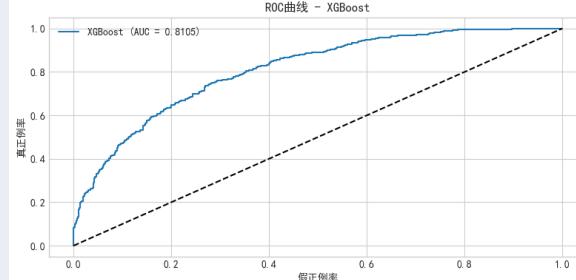
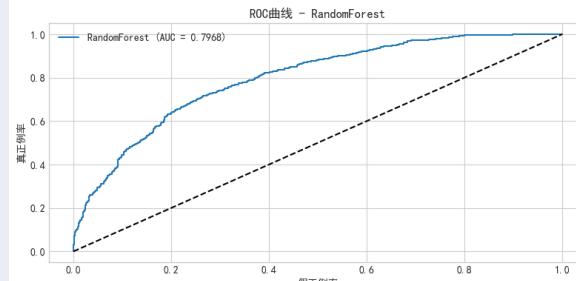
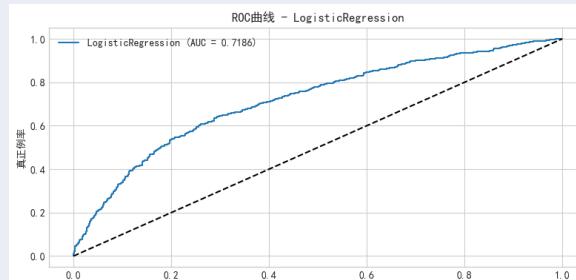
===== 三模型对比（任务4）=====

	Accuracy	Precision	Recall	F1	ROC-AUC
XGBoost	0.722727	0.774306	0.695426	0.732749	0.810502
RandomForest	0.723864	0.741870	0.758836	0.750257	0.796843
LogisticRegression	0.656250	0.663014	0.754678	0.705882	0.718604

•最佳模型：XGBoost

•核心原因：

- 该任务为相对平衡的二分类问题，ROC-AUC (0.8105) 最高，说明其对“社会渠道”和“自有渠道”的区分能力最强。
- 虽然随机森林的 F1 分数 (0.7503) 略高于 XGBoost (0.7327)，但 XGBoost 的精确率 (0.7743) 更高。





任务5：最近使用操作系统偏好

有效样本数： 7836

```
drop_cols = ["用户ID", "客户类型", "终端品牌"]
X, y, _ = preprocess_features(df5, target_col="最近使用操作系统偏好", drop_cols=drop_cols)
```

删除“终端品牌”字段以解决数据泄露

===== 三模型对比（任务5）=====

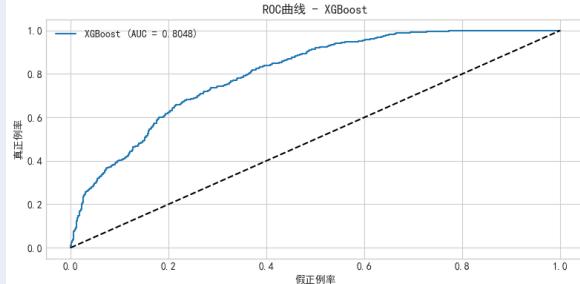
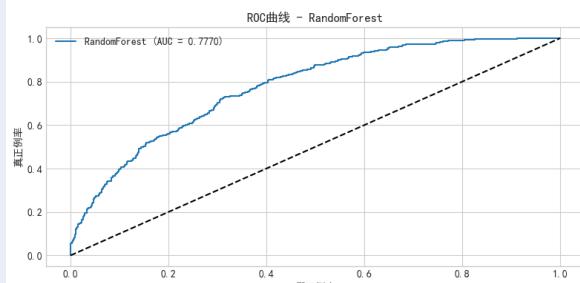
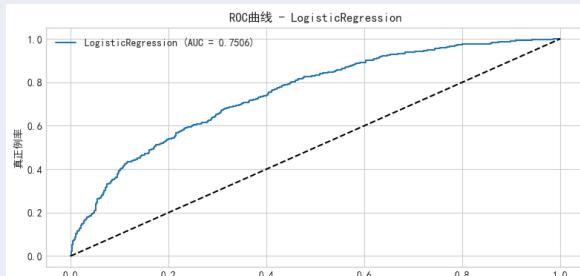
	Accuracy	Precision	Recall	F1	ROC-AUC
XGBoost	0.727679	0.680685	0.663126	0.671791	0.804778
RandomForest	0.703444	0.627297	0.725341	0.672766	0.776970
LogisticRegression	0.688776	0.684665	0.481032	0.565062	0.750607

•最佳模型：XGBoost

•核心原因：

•XGBoost 在准确率（0.7277）和ROC-AUC（0.8048）上均为最高，综合表现最优。

•其精确率（0.6807）和召回率（0.6631）更均衡，说明对“ANDROID”和“IOS”的识别能力更稳定。





05

模型整体对比与总结



总结

任务	模型	最佳指标	原因
任务 2：预测是否欠费（严重不平衡二分类）	XGBoost	ROC-AUC=0.7548, F1=0.3532	该任务核心需求是识别少数“欠费”样本，XGBoost 的 ROC-AUC（反映整体区分能力）和 F1 分数（平衡精确率与召回率）均最优。其召回率（0.4486）高于随机森林，能更好捕捉欠费样本，且通过梯度提升策略缓解了数据不平衡带来的偏置，表现优于偏向多数类的随机森林和线性拟合的逻辑回归。
任务 3：预测终端类型（2G/3G/4G，多分类）	RandomForest	Macro-F1=0.6313	多分类任务需关注对所有类别的均衡表现，RandomForest 的宏 F1 显著高于其他模型，对样本量较少的“3G”类别（召回率 0.42）识别能力更优，未出现完全无法预测的类别。其集成学习特性能有效处理多类别间的复杂关系，避免被占比高的“4G”类别主导，均衡性优于 XGBoost 和逻辑回归。
任务 4：预测渠道类型（二分类）	XGBoost	ROC-AUC=0.8105, 精确率 = 0.7743	任务为相对平衡的二分类，XGBoost 的 ROC-AUC 最高，说明类别区分能力最强；精确率（0.7743）优于其他模型，意味着预测“社会渠道”的样本中实际准确率更高，误判更少。其梯度提升机制能精准捕捉渠道类型与用户消费、流量特征的非线性关联，拟合能力强于线性模型和随机森林。
任务 5：预测操作系统偏好（二分类）	XGBoost	ROC-AUC=0.8048, 准确率 = 0.7277	XGBoost 综合表现最优，准确率和 ROC-AUC 均为最高，且精确率（0.6807）与召回率（0.6631）更均衡，无明显偏置。操作系统偏好与用户行为特征（如流量使用、收入）的关系呈非线性，XGBoost 通过树结构迭代优化，能高效学习复杂模式，优于逻辑回归的线性拟合和随机森林的并行集成效果。



感谢观看！

THANKS FOR WATCHING

汇报人：钟忠权

时间：2025.11.17